

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Алтайский государственный технический университет им. И.И. Ползунова»
Университетский технологический колледж
Кафедра Информационные системы в экономике

Отчет защищен с оценкой _____

Преподаватель _____ С.В. Умбетов

«____» _____ 2026 г.

Отчет по лабораторной работе №1
по дисциплине «Устройство и функционирование
интеллектуальных информационных систем»
«Работа с табличными данными в Pandas»

ЛР 09.02.08.02.001

Студент группы	<u>1ИИС-41</u>	<u>Н.М. Аникин</u>
	группа	и.о., фамилия
Преподаватель	<u>старший преподаватель, доцент</u>	<u>С.В. Умбетов</u>
	должность, ученая степень	и.о., фамилия

Барнаул 2026

Лабораторная работа №1

Работа с табличными данными в Pandas

Цель работы: освоить базовые и продвинутые приёмы работы с табличными данными в библиотеке Pandas на примере реального набора данных о пассажирах «Титаника». Научиться загружать, исследовать, фильтровать, агрегировать и преобразовывать табличные данные, а также делать аналитические выводы на основе полученных результатов.

Задачи работы:

1. Изучить теоретические основы работы с библиотекой Pandas: объекты Series и DataFrame, их создание и основные свойства.
2. Освоить чтение данных из CSV-файлов с помощью функции `pd.read_csv()` и её параметров.
3. Научиться получать первичную информацию о датафрейме с помощью методов `.head()` , `.tail()` , `.info()` , `.describe()` .
4. Освоить индексацию и доступ к данным через `.loc` , `.iloc` и обращение к столбцам.
5. Научиться фильтровать данные по одному и нескольким условиям с использованием логических операторов.
6. Освоить статистические методы (`.mean()` , `.max()` , `.min()` , `.sum()` , `.std()` , `.count()`) и их применение к датафреймам и отдельным столбцам.
7. Изучить группировку данных с помощью `.groupby()` и агрегацию через `.agg()` .
8. Научиться строить сводные таблицы с помощью `.pivot_table()` .
9. Освоить работу с пропущенными значениями: обнаружение, удаление, заполнение.
10. Научиться создавать новые признаки на основе существующих с использованием арифметических операций, `pd.cut()` и `.apply()` .
11. Провести комплексный аналитический анализ датасета Titanic и сформулировать содержательные выводы.
12. Закрепить полученные навыки ответами на контрольные вопросы.

Задание к работе: выполнить задачи 1–12 в соответствии с условиями.

Задание принял: _____



Аникин Н.М.

Подпись

Ход работы

Ссылка на GitHub-репозиторий: https://github.com/itsqwit/anikin_1iis41

Задача 1. Загрузка и первичный осмотр данных

- Скачайте датасет train.csv с Kaggle (соревнование Titanic — Machine Learning from Disaster).
- Загрузите данные в DataFrame с помощью `pd.read_csv()`.
- Выведите первые 10 строк таблицы с помощью `.head(10)`.
- Выведите последние 5 строк с помощью `.tail()`.

Titanic - Machine Learning from Disaster

Overview Data Code Models Discussion Leaderboard Rules

train.csv (61.19 kB)

Download

Detail Compact Column

10 of 12 columns

About this file

contains data

Рисунок 1 – скачивание датасета train.csv

```
import pandas as pd

titanic = pd.read_csv('train.csv')

display(titanic.head(10))
display(titanic.tail())
```

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S
5	6	0	3	Moran, Mr. James	male	NaN	0	0	330877	8.4583	NaN	Q
6	7	0	1	McCarthy, Mr. Timothy J	male	54.0	0	0	17463	51.8625	E46	S
7	8	0	3	Palsson, Master. Gosta Leonard	male	2.0	3	1	349909	21.0750	NaN	S
8	9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27.0	0	2	347742	11.1333	NaN	S
9	10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14.0	1	0	237736	30.0708	NaN	C
886	887	0	2	Montvila, Rev. Juozas	male	27.0	0	0	211536	13.00	NaN	S
887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.00	B42	S
888	889	0	3	Johnston, Miss. Catherine Helen "Carrie"	female	NaN	1	2	W./C. 6607	23.45	NaN	S
889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.00	C148	C
890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.75	NaN	Q

Рисунок 2 – загрузка данных в DataFrame, вывод первых 10 и последних 5 строк таблицы

Задача 2. Получение информации о датафрейме

- Используйте метод `.info()` для получения информации о типах данных и количестве непустых значений.
- Примените `.describe()` к числовым столбцам.
- Примените `.describe(include=['object'])` к текстовым столбцам.

```
[41]
✓ 0 сек.
▶ titanic.info()
  titanic.describe()
  titanic.describe(include=['object'])
```

```
... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
#   Column      Non-Null Count  Dtype
---  -
0   PassengerId  891 non-null    int64
1   Survived     891 non-null    int64
2   Pclass       891 non-null    int64
3   Name         891 non-null    object
4   Sex          891 non-null    object
5   Age          714 non-null    float64
6   SibSp        891 non-null    int64
7   Parch        891 non-null    int64
8   Ticket       891 non-null    object
9   Fare         891 non-null    float64
10  Cabin        204 non-null    object
11  Embarked     889 non-null    object
dtypes: float64(2), int64(5), object(5)
memory usage: 83.7+ KB
```

	Name	Sex	Ticket	Cabin	Embarked
count	891	891	891	204	889
unique	891	2	681	147	3
top	Dooley, Mr. Patrick	male	347082	G6	S
freq	1	577	7	4	644

Рисунок 3 – использование `.info()` и применение `.describe()` к числовым и текстовым столбцам

Задача 3. Работа с Series

- Выберите любой текстовый столбец из DataFrame (например, Embarked) и преобразуйте его в Series.
- Установите произвольный индекс для первых 5 элементов этой Series.

- Получите доступ к элементам с помощью `.loc` и `.iloc` .

```
embarked_series = pd.Series(titanic['Embarked']).head()
embarked_series.index=["Первый", "Второй", "Третий", "Четвертый", "Пятый"]
display(embarked_series)
display(embarked_series.loc[["Третий", "Четвертый", "Пятый"]])
display(embarked_series.iloc[[0, 1]])
```

...

	Embarked
Первый	S
Второй	C
Третий	S
Четвертый	S
Пятый	S

dtype: object

	Embarked
Третий	S
Четвертый	S
Пятый	S

dtype: object

	Embarked
Первый	S
Второй	C

dtype: object

Рисунок 4 – преобразование столбца в Series, установка произвольного индекса для первых 5 элементов, получение доступа к элементам через `.loc` и `.iloc`

Задача 4. Статистические методы

- Вычислите средний возраст пассажиров с помощью `.mean()` .
- Найдите максимальную и минимальную стоимость билета.
- Вычислите стандартное отклонение для столбца с возрастом.

```
display(titanic.Age.mean())
display(titanic.Fare.min())
display(titanic.Fare.max())
display(titanic.Age.std())

... np.float64(29.69911764705882)
0.0
512.3292
14.526497332334044
```

Рисунок 5 – применение .mean(), .min(), .max() и .std()

Задача 5. Фильтрация данных по условиям

- Отфильтруйте пассажиров, чей возраст превышает 30 лет.
- Отфильтруйте пассажиров со стоимостью билета выше средней по всему датасету.
- Найдите пассажиров из первого класса (Pclass == 1) женского пола.
- Вычислите средний возраст для отфильтрованной группы из предыдущего пункта.

```
display(titanic[titanic.Age > 30])
display(titanic[titanic.Fare > titanic.Fare.mean()])
filtered1 = titanic[(titanic.Pclass == 1) & (titanic.Sex == 'female')]
display(filtered1)
display(filtered1.Age.mean())
```

Рисунок 6 – фильтрация пассажиров по заданным условиям, вычисление среднего возраста для отфильтрованной группы

...

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S
6	7	0	1	McCarthy, Mr. Timothy J	male	54.0	0	0	17463	51.8625	E46	S
11	12	1	1	Bonnell, Miss. Elizabeth	female	58.0	0	0	113783	26.5500	C103	S
...	...	...	...	...	...	...	...	...	...	...	...	...
873	874	0	3	Vander Cruyssen, Mr. Victor	male	47.0	0	0	345765	9.0000	NaN	S
879	880	1	1	Potter, Mrs. Thomas Jr (Lily Alexenia Wilson)	female	56.0	0	1	11767	83.1583	C50	C
881	882	0	3	Markun, Mr. Johann	male	33.0	0	0	349257	7.8958	NaN	S
885	886	0	3	Rice, Mrs. William (Margaret Norton)	female	39.0	0	5	382652	29.1250	NaN	Q
890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.7500	NaN	Q

305 rows x 12 columns

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
6	7	0	1	McCarthy, Mr. Timothy J	male	54.0	0	0	17463	51.8625	E46	S
23	24	1	1	Sloper, Mr. William Thompson	male	28.0	0	0	113788	35.5000	A6	S
27	28	0	1	Fortune, Mr. Charles Alexander	male	19.0	3	2	19950	263.0000	C23 C25 C27	S
...	...	...	...	...	...	...	...	...	...	...	...	...
856	857	1	1	Wick, Mrs. George Dennick (Mary Hitchcock)	female	45.0	1	1	36928	164.8667	NaN	S
863	864	0	3	Sage, Miss. Dorothy Edith "Dolly"	female	NaN	8	2	CA. 2343	69.5500	NaN	S
867	868	0	1	Roebing, Mr. Washington Augustus II	male	31.0	0	0	PC 17590	50.4958	A24	S
871	872	1	1	Beckwith, Mrs. Richard Leonard (Sallie Monypeny)	female	47.0	1	1	11751	52.5542	D35	S
879	880	1	1	Potter, Mrs. Thomas Jr (Lily Alexenia Wilson)	female	56.0	0	1	11767	83.1583	C50	C

211 rows x 12 columns

Рисунок 7 – вывод результатов (1)

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
11	12	1	1	Bonnell, Miss. Elizabeth	female	58.0	0	0	113783	26.5500	C103	S
31	32	1	1	Spencer, Mrs. William Augustus (Marie Eugenie)	female	NaN	1	0	PC 17569	146.5208	B78	C
52	53	1	1	Harper, Mrs. Henry Sleeper (Myna Haxtun)	female	49.0	1	0	PC 17572	76.7292	D33	C
...	...	...	...	...	...	...	...	...	...	...	...	...
856	857	1	1	Wick, Mrs. George Dennick (Mary Hitchcock)	female	45.0	1	1	36928	164.8667	NaN	S
862	863	1	1	Swift, Mrs. Frederick Joel (Margaret Welles Ba...	female	48.0	0	0	17466	25.9292	D17	S
871	872	1	1	Beckwith, Mrs. Richard Leonard (Sallie Monypeny)	female	47.0	1	1	11751	52.5542	D35	S
879	880	1	1	Potter, Mrs. Thomas Jr (Lily Alexenia Wilson)	female	56.0	0	1	11767	83.1583	C50	C
887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.0000	B42	S
94 rows x 12 columns												
np.float64(34.61176470588235)												

Рисунок 8 – вывод результатов (2)

Задача 6. Комбинированная фильтрация и статистика

- Найдите всех пассажиров, которые выжили (Survived == 1) и были моложе 18 лет.
- Для этой группы вычислите среднюю стоимость билета и количество пассажиров.

```

filtered2 = titanic[titanic.Survived == 1] & (titanic.Age < 18)]
display(filtered2)
display(filtered2.Fare.mean())
display(len(filtered2))

```

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
9	10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14.00	1	0	237736	30.0708	NaN	C
10	11	1	3	Sandstrom, Miss. Marguerite Rut	female	4.00	1	1	PP 9549	16.7000	G6	S
22	23	1	3	McGowan, Miss. Anna "Annie"	female	15.00	0	0	330923	8.0292	NaN	Q
39	40	1	3	Nicola-Yarred, Miss. Jamila	female	14.00	1	0	2651	11.2417	NaN	C
43	44	1	2	Laroche, Miss. Simonne Marie Anne Andree	female	3.00	1	2	SC/Paris 2123	41.5792	NaN	C
...	...	...	...	...	...	...	...	...	...	...	...	...
830	831	1	3	Yasbeck, Mrs. Antoni (Selini Alexander)	female	15.00	1	0	2659	14.4542	NaN	C
831	832	1	2	Richards, Master. George Sibley	male	0.83	1	1	29106	18.7500	NaN	S
853	854	1	1	Lines, Miss. Mary Conover	female	16.00	0	1	PC 17592	39.4000	D28	S
869	870	1	3	Johnson, Master. Harold Theodor	male	4.00	1	1	347742	11.1333	NaN	S
875	876	1	3	Najib, Miss. Adele Kiamie "Jane"	female	15.00	0	0	2667	7.2250	NaN	C

61 rows x 12 columns
np.float64(34.857309836065575)
61

Рисунок 9 – применение комбинированной фильтрации, вычисление средней стоимости билета и количества пассажиров

Задача 7. Группировка данных

- Сгруппируйте пассажиров по классу билета и вычислите средний возраст в каждом классе.
- Для каждой группы также посчитайте количество пассажиров и среднюю стоимость билета.
- Отсортируйте результат по средней стоимости билета в порядке убывания.

```

grouped1 = titanic.groupby('Pclass')[['Age', 'Fare']].agg({'Age': 'mean', 'Fare': ['count', 'mean']}).sort_values(by = ('Fare', 'mean'), ascending = False)
display(grouped1)

```


	Age	Fare
	mean	count mean
Pclass		
1	38.233441	216 84.154687
2	29.877630	184 20.662183
3	25.140620	491 13.675550

Рисунок 10 – группировка пассажиров по классу билета, вычисление среднего возраста, стоимости билетов и количества пассажиров в каждом классе, сортировка результата по средней стоимости билета в порядке убывания

Задача 8. Сводная таблица

- Постройте сводную таблицу с помощью `.pivot_table()`, где:
 - значения — доля выживших (`Survived`);
 - строки — классы билета (`Pclass`);
 - столбцы — пол (`Sex`).

- Проанализируйте, в каких классах и среди какого пола доля выживших выше.



```
titanic.pivot_table(values='Survived', index='Pclass', columns='Sex', aggfunc='mean')
```

	Sex	female	male
Pclass			
1		0.968085	0.368852
2		0.921053	0.157407
3		0.500000	0.135447

Рисунок 11 – построение сводной таблицы

Наибольшая доля выживших у пассажиров женского пола 1 и 2 класса. Вероятно, это связано с тем, что пассажиром 1 и 2 классов, а особенно женщинам и детям, отдавали высший приоритет при посадке в спасательные шлюпки. Также каюты первых классов находились ближе к палубам.

Задача 9. Работа с пропущенными значениями

- Выведите количество и процент пропусков в каждом столбце.
- Заполните пропуски в столбце Embarked самым частым значением, а в столбце Age — медианой.
- Проверьте, есть ли дубликаты по столбцу PassengerId, и удалите их.

```
display(titanic.isnull().sum())
display(titanic.isnull().sum() / len(titanic) * 100)
```

```
...
0
PassengerId  0
Survived     0
Pclass       0
Name         0
Sex          0
Age         177
SibSp        0
Parch        0
Ticket       0
Fare         0
Cabin       687
Embarked     2
```

dtype: int64

```
0
PassengerId  0.000000
Survived     0.000000
Pclass       0.000000
Name         0.000000
Sex          0.000000
Age         19.865320
SibSp        0.000000
Parch        0.000000
Ticket       0.000000
Fare         0.000000
Cabin       77.104377
Embarked     0.224467
```

dtype: float64

Рисунок 12 – вывод количества и процента пропусков в каждом столбце

```
titanic.isnull().sum()
titanic.isnull().sum() / len(titanic) * 100

embarked_top = titanic.Embarked.describe(include=['object'])['top']
titanic['Embarked'] = titanic['Embarked'].fillna(embarked_top)
age_median = titanic.Age.describe()['50%']
titanic['Age'] = titanic['Age'].fillna(age_median)

display(titanic.duplicated(subset=['PassengerId']).sum())
titanic.drop_duplicates(subset=['PassengerId'], keep='first')
```

```
np.int64(0)
```

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S
...	...	...	...	...	...	...	...	...	...	...	...	...
886	887	0	2	Montvila, Rev. Juozas	male	27.0	0	0	211536	13.0000	NaN	S
887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.0000	B42	S
888	889	0	3	Johnston, Miss. Catherine Helen "Carrie"	female	28.0	1	2	W./C. 6607	23.4500	NaN	S
889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.0000	C148	C
890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.7500	NaN	Q

891 rows x 12 columns

Рисунок 13 – заполнение пропусков в Embarked самым частым значением, в Age медианой, проверка наличия дубликатов в PassengerId и удаление их

```
titanic.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
#   Column          Non-Null Count  Dtype
---  -
0   PassengerId     891 non-null   int64
1   Survived        891 non-null   int64
2   Pclass         891 non-null   int64
3   Name            891 non-null   object
4   Sex             891 non-null   object
5   Age             891 non-null   float64
6   SibSp           891 non-null   int64
7   Parch           891 non-null   int64
8   Ticket          891 non-null   object
9   Fare            891 non-null   float64
10  Cabin           204 non-null   object
11  Embarked        891 non-null   object
dtypes: float64(2), int64(5), object(5)
memory usage: 83.7+ KB
```

Рисунок 14 – проверка заполнения

Пропуски в Embarked и Age заполнены. Количество PassengerId не изменилось после удаления дубликатов, значит их не было.

Задача 10. Создание новых признаков и расширенный анализ

- Создайте новый признак $\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$.
- Создайте признак $\text{IsAlone} = 1$, если $\text{FamilySize} == 1$, иначе 0.
- Создайте признак AgeGroup с помощью `pd.cut()` (группы: ребёнок 0–12, подросток 13–18, молодой 19–35, взрослый 36–60, пожилой 60+).
- Проведите анализ: для каждой возрастной группы вычислите:
 - долю выживших;
 - среднюю стоимость билета;
 - количество пассажиров.
- Постройте сводную таблицу по возрастным группам и сделайте выводы о том, какие возрастные категории выживали чаще.

```
titanic['FamilySize'] = titanic['SibSp'] + titanic['Parch'] + 1
titanic['IsAlone'] = titanic['FamilySize'].apply(lambda x: 1 if x == 1 else 0)
titanic['AgeGroup'] = pd.cut(titanic['Age'],
                              bins=[0, 12, 18, 35, 60, 100],
                              labels=['ребёнок', 'подросток', 'молодой', 'взрослый', 'пожилый'])

display(titanic)
```

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	FamilySize	IsAlone	AgeGroup	
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S	2	0	молодой
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C	2	0	взрослый
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S	1	1	молодой
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S	2	0	молодой
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S	1	1	молодой
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
886	887	0	2	Montvila, Rev. Juozas	male	27.0	0	0	211536	13.0000	NaN	S	1	1	молодой
887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.0000	B42	S	1	1	молодой
888	889	0	3	Johnston, Miss. Catherine Helen "Carrie"	female	28.0	1	2	W./C. 6607	23.4500	NaN	S	4	0	молодой
889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.0000	C148	C	1	1	молодой
890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.7500	NaN	Q	1	1	молодой

891 rows x 15 columns

Далее:

New interactive sheet

Рисунок 15 – создание новых признаков

```

age_analysis = titanic.groupby('AgeGroup')[['Survived', 'Fare']].agg({'Survived': 'mean', 'Fare': ['mean', 'count']})
display(age_analysis)

```

```

/tmp/ipykernel_948/467736969.py:1: FutureWarning: The default of observed=False is deprecated and will be changed to True
age_analysis = titanic.groupby('AgeGroup')[['Survived', 'Fare']].agg({'Survived': 'mean', 'Fare': ['mean', 'count']})

```

	Survived	Fare	
	mean	mean	count
AgeGroup			
ребёнок	0.579710	31.536352	69
подросток	0.428571	33.451313	70
молодой	0.353271	27.356166	535
взрослый	0.400000	44.259658	195
пожилой	0.227273	41.371214	22

Рисунок 16 – доля выживших, средняя стоимость билета и количество пассажиров для каждой возрастной группы




Рисунок 17 – построение сводной таблицы по возрастным группам

Чаще всего выживали дети и подростки. Вероятно, это связано с тем, что детям отдавали приоритет в посадке на спасательные шлюпки, а также с тем, что детям было физически проще добраться до отдаленной части корабля, чем пожилым людям.

Задача 11. Комплексный аналитический отчёт

- Определите топ-3 порта посадки по количеству пассажиров.
- Для каждого порта вычислите:
 - средний возраст;
 - среднюю стоимость билета;
 - долю выживших;
 - долю пассажиров первого класса.
- Сделайте вывод о том, какой порт посадки связан с наибольшей долей выживших и почему.

```
port_counts = titanic.groupby('Embarked')['PassengerId'].count().sort_values(ascending=False)
display(port_counts)
```

PassengerId	
Embarked	
S	646
C	168
Q	77

dtype: int64

Рисунок 18 – определение топ-3 портов посадки по количеству пассажиров

```
embarked_stats = titanic.groupby('Embarked').agg({'Age': 'mean', 'Fare': 'mean', 'Survived': 'mean', 'Pclass': lambda x: (x == 1).mean()})
display(embarked_stats)
```

	Age	Fare	Survived	Pclass
C	30.178095	59.954144	0.553571	0.505952
Q	28.032468	13.276030	0.389610	0.025974
S	29.307663	27.243651	0.339009	0.199690

Рисунок 19 – средний возраст, средняя стоимость билета, доля выживших и доля пассажиров первого класса для каждого порта

Наибольшая доля выживших приходится на порт С (Шербур). Вероятнее всего это связано с тем, что для этого порта доля пассажиров первого класса наибольшая. Как до этого было выяснено в задании 8, пассажиры первого класса статистически выживали значительно чаще.

Задача 12. Сравнительный анализ по размеру семьи

- Сгруппируйте данные по признаку FamilySize и вычислите:
 - долю выживших;
 - средний возраст;
 - среднюю стоимость билета;
 - количество пассажиров.
- Отфильтруйте размеры семей с более чем 10 пассажирами.
- Отсортируйте по доле выживших и выведите результат.
- Сравните: в каких семьях (одиночки, маленькие, большие) доля выживших максимальна? Сделайте выводы.




Рисунок 20 – группировка данных по признаку FamilySize, вычисление характеристик




Рисунок 21 – фильтрация семей с более чем 10 пассажирами, сортировка по доле выживших

Доля выживших максимальна в семьях из 4 человек, близки семьи по 2-3 человека. Вероятно, это связано с тем, что в таких небольших группах было проще координировать действия. Они не теряли друг друга в толпе и успешно добирались до верхней палубы.

Контрольные вопросы

1. Что такое Pandas и для каких задач используется эта библиотека?

Pandas — это наиболее популярная библиотека Python для работы с данными и удобного представления их в табличной форме. Она используется для загрузки, исследования, фильтрации, агрегации и преобразования табличных данных.

2. Чем Series отличается от обычного списка Python? Как создать Series с пользовательским индексом?

Series отличается от обычного списка Python, где доступ к элементу осуществляется только по его порядковому номеру, тем, что в Series индексом может выступать что угодно.

Чтобы создать Series с пользовательским индексом, нужно использовать команду `pd.Series()`, передав список элементов и список индексов в параметр `index`:

```
pd.Series(["Значение1", "Значение2"], index=["Индекс1", "Индекс2"])
```

3. В чём разница между `.loc` и `.iloc` при доступе к элементам Series?

Метод `.loc` принимает определённые текстовые метки из индекса. Метод `.iloc` принимает на вход строго порядковые номера элементов.

4. Как создать DataFrame из словаря? Как задать названия колонок и индекс вручную?

Чтобы создать DataFrame из словаря, нужно передать его в конструктор: `df = pd.DataFrame({'col1': [1, 2], 'col2': [3, 4]})`.

Чтобы задать названия колонок и индексы вручную, DataFrame можно создать из списка списков, указав параметры `columns` и `index`: `2, 3], [2, 3, 4]], columns=['foo', 'bar', 'baz'], index=['foobar', 'foobaz'])`

5. Какие параметры функции `pd.read_csv()` вы знаете? Для чего используется параметр `usecols` ?

Я знаю параметры `sep`, `decimal`, `names`, `skiprows`, `usecols`, `index_col`, `parse_dates`. Параметр `usecols` позволяет загрузить только определённые столбцы, что ускоряет чтение и экономит память

6. Какую информацию выводит метод .info() ? Какие параметры можно ему передать?

Метод выводит информацию индексе, о количестве колонок, о самих колонках (название колонки, количество непустых элементов в колонке, тип колонки), суммарное количество колонок по типам и использование памяти.

В .info() можно передать параметры:

- `verbose` - печатать ли информацию о DataFrame полностью;
- `memory_usage` - печатать ли потребление памяти (True / False / 'deep');
- `null_counts` - подсчитывать ли количество пустых элементов (по умолчанию True).

7. Что показывает метод .describe() для числовых данных и для текстовых данных?

Для числовых значений выводится число непропущенных значений, среднее, стандартное отклонение, диапазон, медиану, 0.25 и 0.75 квантили.

Для текстовых данных выводится количество непустых строк, уникальных значений, самое частое значение (top) и частота этого значения (freq).

8. Как получить доступ к отдельному столбцу DataFrame? Какие два способа существуют?

Доступ к колонке можно получить с помощью `df['column_name']` или `df.column_name`.

9. Как отфильтровать DataFrame по одному условию? Как комбинировать несколько условий?

Для фильтрации по одному условию нужно передать логическое выражение внутрь квадратных скобок датафрейма. Пример: `titanic[titanic.Age > 30]`.

Для комбинирования нескольких условий используются операторы `&` (логическое И) и `|` (логическое ИЛИ). Условия при этом заключаются в скобки. Пример: `titanic[(titanic.Age < 30) | (titanic.Pclass == 1)]`.

10. Какие статистические методы можно применять к DataFrame и Series? Что произойдёт, если применить .mean() ко всему DataFrame с текстовыми столбцами?

Можно применять следующие статистические методы: `.max()` – максимум; `.min()` – минимум; `.mean()` - среднее значение; `.sum()` – сумма; `.count()` - количество непустых элементов; `.std()` - стандартное отклонение. Если применить метод `.mean()` ко всему DataFrame, результатом его работы станет объект типа Series. При этом в метод можно передать параметр `numeric_only` — определяет, вычислять параметры только по числовым столбцам/строкам или нет (`True/False`).

11. Для чего используется метод .groupby() ? Как применить несколько агрегирующих функций одновременно?

Метод `.groupby()` используется для группировки данных по значениям одного или нескольких столбцов. Чтобы применить несколько агрегирующих функций одновременно, используется метод `.agg()`, в который передается список нужных функций: `.agg(['mean', 'max', 'count'])`.

12. Чем сводная таблица (pivot_table) отличается от обычной группировки? В каких случаях удобнее использовать каждую из них?

Метод `.groupby()` выводит результат в виде одномерной сгруппированной структуры (Series) или плоской таблицы. Метод `.pivot_table()` строит двумерную матричную таблицу, где данные распределяются одновременно по строкам (index) и столбцам (columns), а в ячейках отображается агрегированное значение.

Группировку удобнее использовать для быстрого расчёта метрик по одному признаку, а `pivot_table` — для построения наглядных перекрестных матриц (например, доля выживших в разрезе пола и класса одновременно).

13. Как обнаружить и обработать пропущенные значения в DataFrame? Какие стратегии заполнения пропусков вы знаете?

Обнаружить пропуски можно с помощью связки методов `.isnull().sum()`. Обработать пропуски можно двумя путями: удалить строки с пустотами через `.dropna(subset=[...])` или заполнить их с помощью метода `.fillna()`.

Стратегии заполнения: заполнение константным значением или заполнение математическими метриками признака.

14. Как создать новый признак на основе существующих? Для чего используется метод `pd.cut()`?

Новый признак можно создать с помощью арифметических операций над столбцами (`df['A'] + df['B']`), с помощью применения лямбда-функций через метод `.apply(lambda x: ...)` или с помощью интервального деления.

Функция `pd.cut()` используется для автоматического распределения чисел по заданным возрастным или ценовым интервалам с присвоением текстовых меток (категорий).

15. Как отсортировать `DataFrame` по значениям одного или нескольких столбцов? Как вывести только топ-N строк?

Для сортировки по значениям столбцов используется метод `.sort_values()`.

Чтобы вывести только топ-N строк таблицы, к ней применяется метод `.head(N)`.

Вывод

В ходе этой лабораторной работы мне удалось поработать с библиотекой Pandas и проанализировать реальный набор данных о пассажирах «Титаника».

Я научился загружать табличные данные с помощью `pd.read_csv()`, ограничивать вывод таблицы методами `.head()` и `.tail()`. Научился получать первичную информацию о датафрейме с помощью методов `.head()`, `.tail()`, `.info()` и `.describe()`. Освоил индексацию и доступ к данным через `.loc()` и `.iloc()` и обращение к столбцам. Научился фильтровать данные по одному и нескольким условиям с использованием логических операторов. Освоил статистические методы `.mean()`, `.max()`, `.min()`, `.sum()`, `.std()`, `.count()` и их применение к датафреймам и отдельным столбцам. Изучил группировку данных с помощью `.groupby()` и агрегацию через `.agg()`. Научился строить сводные таблицы с помощью `.pivot_table()`. Освоил работу с пропущенными значениями: научился обнаруживать их, удалять и заполнять. Научился создавать новые признаки на основе существующих с использованием арифметических операций, `pd.cut()` и `.apply()`.

Все полученные навыки я применил для проведения комплексного анализа датасета «Титаник», в результате которого сделал выводы о зависимостях между различными статистическими характеристиками пассажиров. Так, например, стало известно, что пассажиры первых классов имели гораздо более благоприятные к эвакуации условия, что сказалось на доле их выживаемости.

Таким образом, эта лабораторная работа позволила мне овладеть навыками анализа реальных табличных данных и формулирования выводов на основе статистических характеристик, а также узнать назначение библиотеки Pandas, структуру её объектов и основные методы работы с данными.